

Team

*Сборная Руанды по
настольному теннису*

*Prod. by Анастасия,
Сергей,
Алексей*

Преданализ • О базе данных

>> Строка

содержит информацию
о посещении клиентами
интернет-магазина
“Delivery Dron”

>> 1012 строк

>> 15 столбцов

>> 4 канала привлечения:
реклама (3 типа) и
органический

>> Технические данные:
дата и время, о покупке

>> 4 региона: USA, UK,
Германия, Франция

>> 4 девайса: PC, Mac,
Android, iPhone

Исследовательский вопрос



В какой регион и какой рекламный канал инвестировать больше денег на привлечение клиентов в следующем году и обосновать свои предложения?

Преданализ • Дубликаты и выбросы

Удалили аномальные значения:

- Сумма покупки
- Наличие промокода
- Строка-дубликат

Очистили по IQR:

- Стоимость покупки

1012 строк → 972 строк

Дубликаты:

- Регион, Девайс и Канал привлечения

Удалили строки с NaN:

- Регион, Девайс и Канал привлечения

40 удалённых строк


Преданализ • Новые переменная

F (быстрая реклама) — флаг
привлечения клиента через
социальные сети и контекстная
реклама

Почему поделили именно так?

Пользователь изначально не заходит в
соцсети или поисковик ради рекламы, но
часто сталкивается с ней в процессе
просмотра контента. Это делает контакт с
рекламой спонтанным и частым, что
несвойственно email-рассылкам и
рекламы у блогеров

payer — флаг покупки




**Целевая переменная всего
исследования!**

Преданализ • Статистика

5114

Средний чек



Датасета -
Лето

0.26







Мат. ожидание
покупки человека




Датасета -
Быстрая реклама

Преданализ • Доля посещений

Доля посещений



Преданализ • Графики



Преданализ • Графики



Гипотезы

Гипотеза	Метод проверки	Подтвердилась  / Не подтвердилась 
Средний чек отличается в зависимости от региона	Критерий Краскелла-Уоллиса	
Средний чек отличается в зависимости от времени суток	Критерий Краскелла-Уоллиса	
Длительность сессии влияет на сумму покупок	Корреляция Спирмена	
Тип устройства влияет на результат покупки	Логистическая Регрессия	
Тип рекламного канала влияет на результат покупки	Логистическая Регрессия	
Регион влияет на флаг покупки	Логистическая Регрессия	
Время перехода влияет на покупку	Логистическая Регрессия	
По пятницам для регионов USA и UK процент успешных покупок больше	Хи-квадрат	
Летом процент покупок больше	Хи-квадрат	
В нелетнее время пользователи PC, Mac и iPhone, живущие в USA, UK и Германии с помощью быстрой рекламы чаще покупают.	Хи-квадрат	

Моделирование • Моделирование

1

Подготовка

Целевая переменная - флаг покупки. Оставили только те переменные, которые коррелируют с флагом

2

Логистическая регрессия

Обучили логистическую регрессию. P-value 11 из 13 переменных $> 0.05 \rightarrow$ Модель неточная $\rightarrow$ обучим CatBoost для точности

3

CatBoost

Подобрали лучшую модель с помощью GridSearch, обучили модель.


4

Оценка точности


Macro Recall на тесте: 0.55, что по-прежнему не очень точно, но с учетом малого кол-ва строк - нормально

Моделирование • Моделирование

Важность переменных (CatBoost)



Оценка точности



Наибольшую важность имеют столбцы sessiondurationsec, month, time_period и channel. is_friday и device по также имеют важность, но меньше. регион почти не важен

Выводы • Результаты

Рекомендации:

- Концентрировать рекламу пользователям из **USA** и **UK** по **Пятницам**
- Концентрировать рекламу на **лето**
- В май, сентябрь и октябрь пользователям **PC, Mac** и **iPhone**, живущих в **USA, UK** и **Германии** концентрировать рекламу на **социальные сети** и **контекстную рекламу**.



Ответ на вопрос

That's All

Дашборд: <https://datalens.yandex/mw1f2npokces8>